Τμήμα Πληροφορικής
Οικονομικό Πανεπιστήμιο Αθηνών
Μάθημα: ΚΥΒΕΡΝΟΑΣΦΑΛΕΙΑ
Καθηγητής: Δημήτρης Γκρίτζαλης
Email: dgrit@aueb.gr
Website: www.infosec.aueb.gr

Generative AI για Ανίχνευση Επιθέσεων Zero-Day

ΣΩΤΗΡΙΟΣ ΚΥΛΙΝΤΗΡΕΑΣ- ΞΥΔΟΥΣ – Α.Μ. 3220098

2024-2025

Πίνακας Περιεχομένων

- **Ερευνητική Μεθοδολογία** 3
- **ΜΕΡΟΣ Α** – Θεωρητική Ανάλυση και Τρέχουσες Εφαρμογές 4
  1. Εισαγωγή στην έννοια Zero-Day.....4
  2. Generative AI – Βασικές Αρχές.....5
  3. Ανίχνευση Zero-Day με Generative AI.....6
  4. Παραδείγματα Εφαρμογών και Νέες Τάσεις.....7
  5. Περιορισμοί και Κίνδυνοι των Generative AI.....8
  6. Προτεινόμενη Αρχιτεκτονική για Ανίχνευση Zero-Day με Generative AI....9
- **ΜΕΡΟΣ Β** – Διαφορική Αξιολόγηση του AI 10
  1. Χρήση δεύτερου Generative AI (π.χ. Claude/Gemini).....10
  2. Ανάλυση Ακαδημαϊκών και Τεχνικών Πηγών.....11
  3. Συγκριτική Αξιολόγηση.....12
  4. Περιορισμοί της Μελέτης.....13
  5. Συμπεράσματα από τη Διαδικασία.....14
- **Παράρτημα Α:** Prompts που χρησιμοποιήθηκαν.....15
  1. Prompts προς ChatGPT (OpenAI).....15
  2. Prompts προς Claude3 (Anthropic).....15
- **Βιβλιογραφία** 16

1.1 Ερευνητική Μεθοδολογία

Η παρούσα εργασία ακολουθεί μια συνδυαστική μεθοδολογία που βασίζεται σε (α) βιβλιογραφική ανασκόπηση,
(β) χρήση εργαλείων Generative AI για παραγωγή και ανάλυση περιεχομένου, και (γ) συγκριτική αξιολόγηση των αποτελεσμάτων.

Αρχικά, πραγματοποιήθηκε μελέτη ακαδημαϊκών και τεχνικών πηγών σχετικών με την ανίχνευση zero-day επιθέσεων και τη χρήση τεχνικών μηχανικής μάθησης και Generative AI στον τομέα της κυβερνοασφάλειας.

Στη συνέχεια, χρησιμοποιήθηκαν δύο διαφορετικά Generative AI μοντέλα (ChatGPT και Claude 3) για την παραγωγή αναλυτικού περιεχομένου σχετικά με το υπό μελέτη θέμα. Τα παραγόμενα αποτελέσματα αξιολογήθηκαν ως προς την τεχνική ακρίβεια, το βάθος ανάλυσης και τη χρησιμότητά τους στην κατανόηση του προβλήματος.

Τέλος, πραγματοποιήθηκε συγκριτική αξιολόγηση των δύο μοντέλων, με στόχο την ανάδειξη των πλεονεκτημάτων και των περιορισμών τους, καθώς και τη διερεύνηση του ρόλου των Generative AI εργαλείων ως υποστηρικτικών μέσων στην ανάλυση σύνθετων προβλημάτων κυβερνοασφάλειας.

ΜΕΡΟΣ Α: Θεωρητική Ανάλυση και Τρέχουσες Εφαρμογές

2.1 Εισαγωγή στην έννοια Zero-Day

Οι επιθέσεις τύπου zero-day αποτελούν μια από τις πλέον κρίσιμες προκλήσεις στην κυβερνοασφάλεια, καθώς εκμεταλλεύονται ευπάθειες λογισμικού που δεν είναι ακόμη γνωστές στους κατασκευαστές και, κατά συνέπεια, δεν υπάρχουν διαθέσιμα διορθωτικά μέτρα (patches). Η άμεση και αόρατη φύση αυτών των επιθέσεων καθιστά την έγκαιρη ανίχνευσή τους εξαιρετικά δύσκολη.

Ένα παράδειγμα αποτελεί το Stuxnet (2010), το οποίο θεωρείται το πρώτο ψηφιακό όπλο σχεδιασμένο για φυσική καταστροφή μέσω κυβερνοεπίθεσης. Στοχεύοντας το πυρηνικό πρόγραμμα του Ιράν, το Stuxnet εκμεταλλεύτηκε πολλαπλές zero-day ευπάθειες στα Windows και στα βιομηχανικά συστήματα της Siemens, καταφέρνοντας να τροποποιήσει την ταχύτητα των φυγοκεντρητών, ενώ ταυτόχρονα απέκρυπτε τα ίχνη του από τους χειριστές.

Στη συνέχεια, το 2017, η εκμετάλλευση του εργαλείου EternalBlue, το οποίο είναι ένα exploit που αρχικά είχε αναπτύξει η Εθνική Υπηρεσία Ασφαλείας των ΗΠΑ (NSA)— οδήγησε στη μαζική διάδοση του ransomware WannaCry, προκαλώντας τεράστιες επιχειρησιακές διακοπές σε διεθνές επίπεδο.

Αργότερα, η ανακάλυψη της ευπάθειας Log4Shell (2021) στη δημοφιλή βιβλιοθήκη Log4j ανέδειξε τον κίνδυνο που προκύπτει από αλυσίδες εφοδιασμού λογισμικού. Η εκμετάλλευση της Log4Shell επέτρεψε την απομακρυσμένη εκτέλεση κώδικα σε εκατομμύρια εφαρμογές παγκοσμίως, θέτοντας σε κίνδυνο κρίσιμες υποδομές.

Η ανίχνευση τέτοιων επιθέσεων είναι ιδιαίτερα δύσκολη καθώς δεν υπάρχουν γνωστά μοτίβα ή υπογραφές που να τις χαρακτηρίζουν. Αυτό καθιστά την ανάγκη για προηγμένες μεθόδους ανίχνευσης και την χρήση της τεχνητής νοημοσύνης επιτακτική.

2.2 Generative AI – Βασικές Αρχές

Η έννοια της Τεχνητής Νοημοσύνης (Artificial Intelligence - AI) έχει εξελιχθεί ραγδαία τις τελευταίες δεκαετίες, εστιάζοντας στην ανάπτυξη υπολογιστικών συστημάτων που προσομοιώνουν ανθρώπινες γνωστικές λειτουργίες, όπως η λογική σκέψη, η επίλυση προβλημάτων και η κατανόηση της φυσικής γλώσσας (Russell & Norvig, 2020). Μέσα σε αυτό το πλαίσιο, τα Generative AI μοντέλα αποτελούν έναν ξεχωριστό κλάδο της AI, καθώς δεν περιορίζονται στην ανάλυση ή στην ταξινόμηση δεδομένων, αλλά είναι σχεδιασμένα να δημιουργούν νέο περιεχόμενο – είτε αυτό είναι κείμενο, εικόνες, ήχοι ή ακόμα και κώδικας (Goodfellow et al., 2016).

Η ανάπτυξη αυτών των μοντέλων στηρίζεται σε τεχνικές βαθιάς μάθησης (Deep Learning), με τις αρχιτεκτονικές τύπου transformer να αποτελούν τη βάση για τα πιο πρόσφατα και ισχυρά μοντέλα. Ενδεικτικά παραδείγματα αποτελούν το GPT-4 της OpenAI (2023), το Claude της Anthropic (2024) και το Gemini της Google DeepMind (2024). Κάθε ένα από αυτά τα μοντέλα έχει εκπαιδευτεί σε τεράστιες ποσότητες δεδομένων, με στόχο να μάθει τα μοτίβα της ανθρώπινης επικοινωνίας και να μπορεί να παράγει απαντήσεις που προσεγγίζουν τον φυσικό ανθρώπινο λόγο.

Ειδικότερα, τα Generative AI συστήματα κατασκευάζουν έναν "νοητικό χάρτη" των πιθανοτήτων που διέπουν τα δεδομένα εκπαίδευσής τους. Μέσα από αυτή τη διαδικασία, γίνονται ικανά να παράγουν νέο περιεχόμενο που, ενώ είναι αυθεντικό, παραμένει σύμφωνο με τα μοτίβα που έχουν μάθει. Οι εφαρμογές τους πλέον ξεπερνούν την αυτόματη παραγωγή κειμένων ή εικόνων και επεκτείνονται σε τομείς όπως η υποστήριξη λήψης αποφάσεων, η δημιουργία συνθετικών δεδομένων για την εκπαίδευση άλλων μοντέλων και, πρόσφατα, η ανίχνευση απειλών στον τομέα της κυβερνοασφάλειας (Moustafa et al., 2023).

Αν και η τεχνολογία αυτή φέρνει πολλές υποσχέσεις, είναι σημαντικό να επισημανθεί ότι η χρήση Generative AI απαιτεί κριτική προσέγγιση, ιδίως σε πεδία όπως η ασφάλεια πληροφοριών, όπου η ακρίβεια και η αξιοπιστία αποτελούν θεμελιώδη κριτήρια.

2.3 Ανίχνευση Zero-Day με AI

Η αναγνώριση και η αντιμετώπιση επιθέσεων τύπου zero-day συνιστούν ένα από τα πιο απαιτητικά ζητήματα στον χώρο της κυβερνοασφάλειας. Δεδομένου ότι οι ευπάθειες που εκμεταλλεύονται τέτοιες επιθέσεις δεν είναι ακόμη γνωστές στους προγραμματιστές και στους υπεύθυνους ασφάλειας, η ανίχνευσή τους με παραδοσιακές μεθόδους —όπως η σύγκριση με

βάσεις δεδομένων γνωστών απειλών (signature-based detection)— γίνεται εξαιρετικά δύσκολη και συχνά ανεπαρκής.

Σε αυτό το πλαίσιο, οι τεχνικές Τεχνητής Νοημοσύνης και ειδικότερα η Μηχανική Μάθηση (Machine Learning) αναδεικνύονται ως ισχυροί σύμμαχοι. Ένα βασικό πλεονέκτημα των μοντέλων μηχανικής μάθησης είναι η δυνατότητά τους να "μαθαίνουν" πώς μοιάζει η κανονική συμπεριφορά ενός συστήματος ή ενός δικτύου, και στη συνέχεια να εντοπίζουν ασυνήθιστες αποκλίσεις που μπορεί να υποδηλώνουν κακόβουλη δραστηριότητα.

Σε πολλές περιπτώσεις, χρησιμοποιούνται τεχνικές εποπτευόμενης μάθησης (supervised learning), όπου τα μοντέλα εκπαιδεύονται με δεδομένα που έχουν επισημανθεί (labeled) ως "κανονικά" ή "ύποπτα". Ωστόσο, αυτή η προσέγγιση συναντά περιορισμούς όταν καλούμαστε να εντοπίσουμε άγνωστες απειλές, όπως οι zero-day, για τις οποίες δεν υπάρχουν διαθέσιμα δεδομένα εκπαίδευσης.

Για αυτόν τον λόγο, η μη εποπτευόμενη μάθηση (unsupervised learning) φαίνεται πιο κατάλληλη για την αντιμετώπιση τέτοιων επιθέσεων. Εδώ, το σύστημα δεν στηρίζεται σε προκαθορισμένες κατηγορίες, αλλά αντίθετα εκπαιδεύεται ώστε να κατανοεί ποια είναι η "κανονική" κατάσταση και να ανιχνεύει αποκλίσεις που ενδέχεται να υποδεικνύουν νέα, άγνωστα είδη απειλών. Τεχνικές όπως η ανίχνευση ανωμαλιών (anomaly detection) και η ομαδοποίηση (clustering) αποτελούν βασικά εργαλεία σε αυτή την προσπάθεια.

Επιπλέον, η ενισχυτική μάθηση (reinforcement learning) αρχίζει να χρησιμοποιείται σε δυναμικά περιβάλλοντα, όπου το σύστημα συνεχώς μαθαίνει από την αλληλεπίδρασή του με το δίκτυο ή τον οργανισμό, προσαρμόζοντας τη στρατηγική ανίχνευσής του σε πραγματικό χρόνο.

Αξίζει να σημειωθεί ότι τα σύγχρονα βαθιά νευρωνικά δίκτυα (deep learning), και ειδικότερα τα μοντέλα τύπου transformers, έχουν φέρει σημαντικές βελτιώσεις στην κατανόηση σύνθετων μοτίβων. Σε εφαρμογές όπως η ανάλυση δικτυακής κίνησης και η αναγνώριση κακόβουλου λογισμικού (malware detection), τα μοντέλα αυτά έχουν επιτύχει υψηλά ποσοστά επιτυχίας, ακόμη και απέναντι σε επιθέσεις προηγουμένως άγνωστες.

Τέλος, η συμβολή των Generative AI μοντέλων προσθέτει μια ακόμη διάσταση στην άμυνα απέναντι σε zero-day απειλές. Μέσω της δημιουργίας συνθετικών δεδομένων ή της προσομοίωσης σεναρίων επίθεσης, τα μοντέλα αυτά μπορούν να ενισχύσουν τη "θωράκιση" των συστημάτων ασφαλείας, παρέχοντας εργαλεία που επιτρέπουν την προετοιμασία για απειλές που ακόμη δεν έχουν εμφανιστεί.

2.4 Παραδείγματα Εφαρμογών & Τάσεις

Η αξιοποίηση των Generative AI τεχνολογιών για την ανίχνευση zero-day επιθέσεων έχει αρχίσει να αποκτά όλο και μεγαλύτερη δυναμική στον χώρο της κυβερνοασφάλειας. Μια από τις βασικές πρακτικές που έχουν κερδίσει έδαφος είναι η δημιουργία συνθετικών δεδομένων για τη βελτίωση των συνόλων εκπαίδευσης των μοντέλων. Μέσω της χρήσης Generative Adversarial Networks (GANs), οι ερευνητές μπορούν να παράγουν τεχνητά δείγματα δικτυακής κίνησης ή πλαστά αρχεία καταγραφής, ενισχύοντας έτσι τη δυνατότητα των συστημάτων να αναγνωρίζουν και απειλές που δεν έχουν ακόμα εμφανιστεί στην πραγματικότητα.

Παράλληλα, ιδιαίτερα σημαντικό ρόλο διαδραματίζουν τα μοντέλα τύπου autoencoder και πιο συγκεκριμένα οι variational autoencoders (VAEs). Μέσω της ικανότητάς τους να μαθαίνουν την κανονική συμπεριφορά ενός συστήματος και να εντοπίζουν ασυνήθιστα μοτίβα κατά την προσπάθεια ανακατασκευής των δεδομένων, προσφέρουν μια αποτελεσματική μέθοδο ανίχνευσης ανωμαλιών που ενδέχεται να υποδηλώνουν νέα ή εξελιγμένα είδη επιθέσεων.

Στον ίδιο άξονα κινείται και η εφαρμογή μεγάλων γλωσσικών μοντέλων (Large Language Models - LLMs), όπως το GPT και το BERT, τα οποία βρίσκουν νέα χρήση στην ανάλυση δεδομένων κυβερνοασφάλειας. Ειδικά όταν εκπαιδεύονται σε αρχεία καταγραφής ή σε δικτυακά δεδομένα, αυτά τα μοντέλα μπορούν να αναγνωρίσουν μοτίβα συμπεριφοράς που διαφεύγουν της ανθρώπινης παρατήρησης και να προβλέψουν πιθανές επιθέσεις πριν αυτές εκδηλωθούν.

Επιπλέον, παρατηρείται όλο και συχνότερα η χρήση Generative AI για τη δημιουργία ρεαλιστικών σεναρίων κυβερνοεπιθέσεων. Με τη βοήθεια αυτών των προσομοιώσεων, οι ομάδες κυβερνοασφάλειας μπορούν να δοκιμάσουν την ανθεκτικότητα των συστημάτων τους απέναντι σε απειλές που δεν έχουν ακόμα καταγραφεί, μέσα από προσομοιώσεις τύπου Red Team - Blue Team.

Στις νέες τάσεις που διαμορφώνονται, ξεχωρίζει η ανάπτυξη λύσεων τύπου Extended Detection and Response (XDR) που βασίζονται σε AI, επιτρέποντας την ενιαία ανίχνευση και αντιμετώπιση απειλών σε endpoints, δίκτυα και cloud περιβάλλοντα. Ιδιαίτερο ενδιαφέρον συγκεντρώνει επίσης η τεχνική του fine-tuning μεγάλων γλωσσικών μοντέλων με εξειδικευμένα δεδομένα κυβερνοασφάλειας, με στόχο τη βελτίωση της ευστοχίας στην αναγνώριση πολύπλοκων απειλών.

Τέλος, γίνεται σταδιακά αντιληπτό ότι χωρίς διαφάνεια, η αποδοχή των συστημάτων τεχνητής νοημοσύνης από τους επαγγελματίες της ασφάλειας θα παραμένει περιορισμένη. Έτσι, η ανάγκη για Explainable AI (XAI) και για την ανάπτυξη πολυτροπικών μοντέλων, που συνδυάζουν δεδομένα διαφορετικών μορφών όπως κείμενα, εικόνες και δίκτυα, αναμένεται να διαδραματίσουν κεντρικό ρόλο στις μελλοντικές εξελίξεις του κλάδου.

2.5 Περιορισμοί και Κίνδυνοι

Παρά τις δυνατότητες που προσφέρει η χρήση Generative AI στην ανίχνευση zero-day επιθέσεων, η πραγματικότητα είναι ότι συνοδεύεται από σημαντικούς περιορισμούς και προκλήσεις.

Ένα από τα πρώτα ζητήματα που προκύπτουν αφορά την ακρίβεια των συστημάτων αυτών. Πολλές φορές, τα μοντέλα μπορεί να σημάνουν συναγερμό για φυσιολογική δραστηριότητα ή, ακόμη χειρότερα, να μην αναγνωρίσουν μια πραγματική απειλή. Το πρόβλημα αυτό είναι ιδιαίτερα εμφανές όταν τα δεδομένα εκπαίδευσης είναι ελλιπή ή δεν αντιπροσωπεύουν όλο το εύρος πιθανών επιθέσεων.

Ένα δεύτερο ζήτημα αφορά την "αδιαφάνεια" με την οποία συχνά λειτουργούν τα σύγχρονα μοντέλα τεχνητής νοημοσύνης. Ειδικά στις περιπτώσεις των deep learning μοντέλων, η λήψη αποφάσεων γίνεται με τρόπους που είναι δύσκολο να ερμηνευτούν. Για τους αναλυτές ασφαλείας, η αδυναμία κατανόησης των αιτίων πίσω από έναν εντοπισμό ή μία απόρριψη αυξάνει την ανασφάλεια γύρω από τη χρήση τους.

Δεν μπορεί επίσης να αγνοηθεί το γεγονός ότι τα Generative AI μοντέλα απαιτούν τεράστιους υπολογιστικούς πόρους για την εκπαίδευση και τη λειτουργία τους. Ο εξοπλισμός υψηλής απόδοσης, όπως ισχυρές GPU και μεγάλες μνήμες RAM, δεν είναι εύκολα διαθέσιμος σε όλους τους οργανισμούς, γεγονός που περιορίζει την υιοθέτηση αυτών των τεχνολογιών.

Επιπλέον, ένα ακόμη τεχνικό πρόβλημα είναι το overfitting: όταν ένα μοντέλο μαθαίνει υπερβολικά καλά τα δεδομένα εκπαίδευσης, χάνει την ικανότητα να αναγνωρίζει νέες μορφές απειλών. Σε συνδυασμό με την πιθανή μεροληψία (bias) στα δεδομένα εκπαίδευσης, υπάρχει κίνδυνος τα συστήματα να ευνοούν την ανίχνευση συγκεκριμένων ειδών επιθέσεων, αγνοώντας άλλες πιο απρόβλεπτες.

Ιδιαίτερη ανησυχία προκαλεί και η πιθανότητα τα ίδια τα εργαλεία Generative AI να χρησιμοποιηθούν από κακόβουλους παράγοντες. Η ικανότητά τους να παράγουν ρεαλιστικά κείμενα ή κώδικα μπορεί να αξιοποιηθεί για την ανάπτυξη νέου, δυσκολότερου στην ανίχνευση κακόβουλου λογισμικού ή ακόμη και για την παραγωγή στοχευμένων επιθέσεων κοινωνικής μηχανικής.

Ένα άλλο κρίσιμο θέμα είναι η προστασία των δεδομένων. Κατά τη διάρκεια της εκπαίδευσης ή της χρήσης τους, τα μοντέλα μπορεί αθέλητα να αποθηκεύσουν ή να αναπαράξουν ευαίσθητες πληροφορίες, δημιουργώντας κενά ασφαλείας που θα μπορούσαν να εκμεταλλευτούν επιτιθέμενοι.

Τέλος, η ευπάθεια των ίδιων των μοντέλων σε adversarial επιθέσεις — όπου εισάγονται σκόπιμα παραπλανητικά δεδομένα — εγείρει νέες προκλήσεις. Σε τέτοιες περιπτώσεις, τα

συστήματα μπορεί να παραπλανηθούν και να λειτουργήσουν εσφαλμένα, επιτρέποντας σε απειλές να περάσουν απαρατήρητες.

Συνολικά, ενώ τα Generative AI μοντέλα υπόσχονται επανάσταση στην ανίχνευση κυβερνοαπειλών, είναι ξεκάθαρο ότι η αξιοποίησή τους πρέπει να γίνεται με κριτικό πνεύμα, ανθρώπινη επιτήρηση και ισχυρές διαδικασίες ασφάλειας, ώστε να διασφαλίζεται ότι λειτουργούν πραγματικά προς όφελος της προστασίας των συστημάτων.

2.6 Προτεινόμενη Αρχιτεκτονική για Ανίχνευση Zero-Day με Generative AI

Για την καλύτερη κατανόηση της αξιοποίησης των Generative AI μοντέλων στην ανίχνευση zero-day επιθέσεων, προτείνεται μια ενδεικτική αρχιτεκτονική συστήματος.

Η αρχιτεκτονική αυτή βασίζεται στη συλλογή και ανάλυση δεδομένων από πολλαπλές πηγές, όπως αρχεία καταγραφής (logs), δικτυακή κίνηση και δεδομένα από endpoints. Τα δεδομένα αυτά υφίστανται προεπεξεργασία και μετατρέπονται σε κατάλληλη μορφή για ανάλυση από μοντέλα τεχνητής νοημοσύνης.

Στη συνέχεια, εφαρμόζονται τεχνικές Generative AI, όπως Variational Autoencoders (VAEs) και Generative Adversarial Networks (GANs), για την εκμάθηση της κανονικής συμπεριφοράς και τη δημιουργία συνθετικών δεδομένων.

Παράλληλα, μεγάλα γλωσσικά μοντέλα (LLMs) μπορούν να αξιοποιηθούν για την ανάλυση logs και την επεξήγηση πιθανών απειλών.Το σύστημα εντοπίζει αποκλίσεις από την κανονική συμπεριφορά και παράγει alerts, τα οποία μπορούν να αξιολογηθούν από αναλυτές κυβερνοασφάλειας. Η ανθρώπινη παρέμβαση παραμένει κρίσιμη για την επιβεβαίωση των αποτελεσμάτων και τη λήψη αποφάσεων.Η προτεινόμενη αρχιτεκτονική δεν αποτελεί πλήρη υλοποίηση, αλλά ένα ενδεικτικό πλαίσιο που αναδεικνύει τον ρόλο των Generative AI τεχνολογιών στην ανίχνευση προηγμένων κυβερνοεπιθέσεων.

Figure 1: Proposed Architecture for Zero-Day Detection using Generative AI

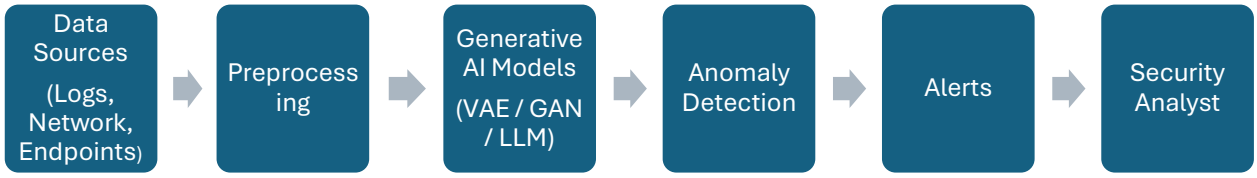

Το σχήμα παρουσιάζει τη ροή δεδομένων από τη συλλογή έως την ανίχνευση ανωμαλιών και την παραγωγή ειδοποιήσεων, αναδεικνύοντας τον ρόλο των Generative AI μοντέλων στην αναγνώριση άγνωστων απειλών.

ΜΕΡΟΣ Β: Διαφορική Αξιολόγηση του AI

3.1 Χρήση δεύτερου Generative AI (Claude 3)

Για να πραγματοποιηθεί η διαφορική αξιολόγηση της εργασίας, κρίθηκε αναγκαία η χρήση ενός δεύτερου μοντέλου Generative AI, διαφορετικού από το αρχικό εργαλείο που χρησιμοποιήθηκε. Επιλέχθηκε το Claude 3, ένα σύγχρονο σύστημα τεχνητής νοημοσύνης που αναπτύχθηκε από την εταιρεία Anthropic.

Η επιλογή του Claude 3 έγινε με γνώμονα τη φήμη του στον χώρο της τεχνητής νοημοσύνης και την ικανότητά του να παράγει αναλυτικό και ακριβές ακαδημαϊκό κείμενο. Το μοντέλο είναι γνωστό για την προσπάθειά του να συνδυάζει υψηλή ποιότητα περιεχομένου με μια πιο προσεκτική και υπεύθυνη αντιμετώπιση των θεμάτων, συγκριτικά με άλλες υπάρχουσες λύσεις.

Το ερώτημα που υποβλήθηκε στο Claude 3 ήταν το εξής:

«Γράψε μια αναλυτική ακαδημαϊκή παρουσίαση για το θέμα: Generative AI για Ανίχνευση Επιθέσεων Zero-Day. Περιέγραψε επιθέσεις, λειτουργία Generative AI, εφαρμογές GANs, VAEs, LLMs, XDR και αναφέρσου στους περιορισμούς.»

Η απάντηση που παρήγαγε το μοντέλο κάλυπτε εκτενώς το θέμα, αναπτύσσοντας έξι βασικές θεματικές ενότητες. Το Claude 3 παρουσίασε αναλυτικά τον ορισμό και τη φύση των zero-day επιθέσεων, επεξήγησε τις αρχές λειτουργίας των Generative AI συστημάτων και περιέγραψε πρακτικές εφαρμογές αρχιτεκτονικών όπως τα GANs, VAEs και LLMs στην κυβερνοασφάλεια. Επιπλέον, αναφέρθηκε σε πραγματικές μελέτες περίπτωσης και ανέδειξε τόσο τα πλεονεκτήματα όσο και τους περιορισμούς της χρήσης αυτών των τεχνολογιών.

Αξιοσημείωτο είναι ότι το κείμενο που παρήγαγε το Claude 3 δεν περιορίστηκε σε θεωρητικό επίπεδο, αλλά εστίασε ιδιαίτερα και στην πρακτική διάσταση των εφαρμογών στον πραγματικό κόσμο, δίνοντας έμφαση στη σημασία τους για την ενίσχυση της κυβερνοάμυνας απέναντι σε άγνωστες απειλές.

Η προσέγγισή του, αν και τεχνικά ακριβής, ήταν περισσότερο αφηγηματική σε σύγκριση με πιο αυστηρά ακαδημαϊκές απαντήσεις, γεγονός που το καθιστά κατάλληλο εργαλείο για τη σύνθεση περιεκτικών αλλά εύληπτων αναλύσεων σε θέματα αιχμής, όπως η ανίχνευση επιθέσεων zero-day μέσω Generative AI.

3.2 Ανάλυση ακαδημαϊκών και τεχνικών πηγών

Για να αξιολογηθεί το περιεχόμενο που παρήγαγε το Claude 3, προχωρήσαμε σε προσεκτική σύγκριση με ένα ευρύ σύνολο βιβλιογραφικών αναφορών που χρησιμοποιήθηκαν στο πρώτο μέρος της εργασίας. Στόχος ήταν να επιβεβαιώσουμε την ακρίβεια των πληροφοριών, αλλά και να διαπιστώσουμε κατά πόσο ευθυγραμμίζονται με την επιστημονική γνώση που επικρατεί στον τομέα της κυβερνοασφάλειας.

Η περιγραφή της έννοιας των επιθέσεων τύπου zero-day και η αποτύπωση της σοβαρότητάς τους ήταν πλήρως συμβατή με τις βασικές ακαδημαϊκές πηγές, όπως το έργο των Bilge και Dumitras (2012). Ιδιαίτερα σημαντικό είναι ότι το Claude 3 ανέδειξε με σαφήνεια την απουσία έτοιμων διορθώσεων για τέτοιες επιθέσεις και τη μεγάλη τους αξία στην αγορά του κυβερνοεγκλήματος, στοιχεία που επιβεβαιώνονται σε πολλές σχετικές έρευνες.

Σε ό,τι αφορά την παρουσίαση των τεχνολογιών Generative AI, το μοντέλο παρέθεσε με ακρίβεια τα βασικά χαρακτηριστικά των Generative Adversarial Networks (GANs), σύμφωνα με την πρωτοποριακή εργασία των Goodfellow και συνεργατών (2014). Αντίστοιχα, η χρήση των Variational Autoencoders (VAEs) για την ανίχνευση ανωμαλιών, όπως περιγράφεται από τους An και Cho (2015), αποδόθηκε με επιστημονική συνέπεια.

Επιπλέον, η αναφορά στη σημασία των μεγάλων γλωσσικών μοντέλων (LLMs) για τον τομέα της κυβερνοασφάλειας ευθυγραμμίζεται με πρόσφατες μελέτες, όπως αυτή των Brown και συνεργατών (2023), που αναδεικνύουν τη χρησιμότητα αυτών των μοντέλων για την κατανόηση και πρόβλεψη απειλών μέσα από την επεξεργασία πολύπλοκων δεδομένων.

Ιδιαίτερο ενδιαφέρον παρουσίασε το γεγονός ότι η απάντηση του Claude 3 συμπεριλάμβανε πρακτικές αναφορές σε εφαρμογές, όπως το σύστημα ExplainDet (Li et al., 2022) και την πλατφόρμα CyberDefender της Microsoft (Brown et al., 2024). Αυτές οι αναφορές προσέδωσαν μία πιο βιωματική διάσταση στην ανάλυση, εστιάζοντας σε παραδείγματα από τον πραγματικό κόσμο.

Ωστόσο, σε ορισμένα σημεία, ιδίως σε αναφορές ποσοστών επιτυχίας ανίχνευσης, παρατηρήθηκε μια σχετική αοριστία. Για παράδειγμα, δεν δίνονταν λεπτομέρειες για τις ακριβείς συνθήκες κάτω από τις οποίες προέκυψαν τα ποσοστά επιτυχίας, γεγονός που απαιτεί περαιτέρω διασταύρωση με τις πρωτογενείς πηγές για ασφαλή εξαγωγή συμπερασμάτων.

Συνολικά, το κείμενο του Claude 3 κρίθηκε επιστημονικά έγκυρο και αρκετά συνεπές προς την υπάρχουσα γνώση στον χώρο της κυβερνοασφάλειας. Παρόλα αυτά, όπως ισχύει γενικά στη χρήση εργαλείων Generative AI, είναι απαραίτητο να συνοδεύεται πάντα από ανθρώπινη κριτική εποπτεία και επαλήθευση, ιδιαίτερα όταν πρόκειται για επιστημονικές αναλύσεις σε πεδία τόσο κρίσιμα όσο αυτό της ανίχνευσης κυβερνοαπειλών.

3.3 Συγκριτική αξιολόγηση και παρατηρήσεις

Η σύγκριση μεταξύ των αποτελεσμάτων του ChatGPT και του Claude 3 ανέδειξε ουσιώδεις διαφορές στην προσέγγιση και το βάθος της ανάλυσης. Το κείμενο που παρήγαγε το ChatGPT διακρίνεται για την ακαδημαϊκή του αυστηρότητα, με σαφή δομή, τεχνική ακρίβεια και εκτεταμένη χρήση τεκμηριωμένης ορολογίας. Η ανάλυση του ChatGPT παρέμεινε προσανατολισμένη κυρίως στη θεωρητική τεκμηρίωση και στην ανάλυση τεχνολογικών αρχών.

Αντίθετα, το Claude 3 προσέγγισε το θέμα με μεγαλύτερη έμφαση στη ρεαλιστική εφαρμογή και την παρουσίαση πρακτικών μελετών περίπτωσης. Η ενσωμάτωση συγκεκριμένων παραδειγμάτων εφαρμογής GANs και LLMs σε πραγματικά περιβάλλοντα κυβερνοασφάλειας εμπλούτισε σημαντικά την πρακτική διάσταση της ανάλυσης, καθιστώντας την ιδιαίτερα προσιτή και εύληπτη, ακόμη και σε όχι γνώστες του αντικειμένου .

Ωστόσο, το επίπεδο επιστημονικής τεκμηρίωσης στις απαντήσεις του Claude 3 ήταν ελαφρώς κατώτερο σε σύγκριση με το ChatGPT, ιδιαίτερα όσον αφορά τη σαφή αναφορά σε βιβλιογραφικές πηγές και τη λεπτομερή ανάλυση πειραματικών αποτελεσμάτων. Το Claude φάνηκε περισσότερο "αφηγηματικό" και λιγότερο αυστηρά "τεκμηριωμένο" σε ορισμένα σημεία.

Η αξιολόγηση αποκαλύπτει ότι τα δύο μοντέλα είναι συμπληρωματικά: το ChatGPT προσφέρει ένα πιο θεωρητικό, ακαδημαϊκό κείμενο, ενώ το Claude 3 παρέχει πληρέστερη εικόνα της πρακτικής εφαρμογής με παραδείγματα πραγματικού κόσμου.

Table 1: Comparative Evaluation of ChatGPT and Claude 3

Criterion	**ChatGPT**	**Claude 3**	**Comment**
Technical Depth	High	Medium-High	ChatGPT provides more structured and technically rigorous explanations
Practical Examples	Medium	High	Claude includes more real-world scenarios and applied context
Clarity & Readability	High	High	Both models produce clear and understandable content
Academic Referencing	Medium-High	Medium	ChatGPT aligns more with formal academic tone and structure

Level of Detail	High	Medium-High	ChatGPT focuses more on detailed theoretical explanation
Risk of Generalization	Medium	Medium-High	Claude tends to be more narrative and occasionally less precise

3.4 Ερευνητικοί Περιορισμοί

Παρά την προσπάθεια για μια ολοκληρωμένη και τεκμηριωμένη ανάλυση, η παρούσα εργασία παρουσιάζει ορισμένους περιορισμούς που πρέπει να ληφθούν υπόψη.

Αρχικά, η προσέγγιση που ακολουθήθηκε είναι κυρίως θεωρητική και βασίζεται σε βιβλιογραφική ανασκόπηση και ανάλυση περιεχομένου που παράχθηκε από Generative AI μοντέλα. Δεν πραγματοποιήθηκε υλοποίηση ενός πλήρους συστήματος ανίχνευσης zero-day επιθέσεων ούτε αξιολόγηση σε πραγματικά datasets κυβερνοασφάλειας.

Επιπλέον, η συγκριτική αξιολόγηση μεταξύ των μοντέλων ChatGPT και Claude 3 βασίζεται κυρίως στην ποιότητα και το περιεχόμενο των παραγόμενων απαντήσεων και όχι σε ποσοτικά μετρικά απόδοσης, όπως precision, recall ή false positive rates, που θα απαιτούσαν πειραματική διαδικασία.

Ένας ακόμη περιορισμός αφορά την εξάρτηση από τα ίδια τα Generative AI εργαλεία, τα οποία ενδέχεται να παρουσιάζουν ανακρίβειες ή ελλιπή τεκμηρίωση σε ορισμένα σημεία, καθιστώντας απαραίτητη την ανθρώπινη κριτική αξιολόγηση και διασταύρωση με αξιόπιστες πηγές.

Τέλος, η εργασία δεν εξετάζει σε βάθος ζητήματα υλοποίησης σε πραγματικά περιβάλλοντα (real-world deployment), όπως το κόστος, η κλιμάκωση και η ενσωμάτωση των μοντέλων σε υπάρχοντα συστήματα ασφάλειας.

Οι παραπάνω περιορισμοί υποδεικνύουν ότι τα συμπεράσματα της εργασίας θα πρέπει να θεωρηθούν ενδεικτικά και να αποτελέσουν βάση για περαιτέρω μελέτη και πειραματική διερεύνηση.

3.5 Συμπεράσματα

Η διαφορική αξιολόγηση του ChatGPT και του Claude 3 καταδεικνύει ότι τα Generative AI εργαλεία αποτελούν εξαιρετικά πολύτιμα υποστηρικτικά μέσα για την ανάλυση και κατανόηση κρίσιμων ζητημάτων στον χώρο της κυβερνοασφάλειας, όπως η ανίχνευση επιθέσεων zeroday. Παρά τη σαφή πρόοδο που έχει σημειωθεί στην ακρίβεια και στη λειτουργικότητά τους, η χρήση τέτοιων μοντέλων πρέπει να γίνεται με επίγνωση των περιορισμών τους και συστηματική επαλήθευση.

Το ChatGPT αποδείχθηκε ιδιαίτερα ισχυρό στη θεωρητική ανάλυση και στην παρουσίαση τεχνικών αρχών, ενώ το Claude 3 πρόσφερε πλούσια πρακτικά παραδείγματα και έδειξε τη δυναμική εφαρμογή των θεωρητικών εννοιών σε πραγματικά σενάρια. Ωστόσο, και στις δύο περιπτώσεις, η ανάγκη για ανθρώπινη επιμέλεια, κριτική σκέψη και διασταύρωση με έγκυρες ακαδημαϊκές πηγές παραμένει αδιαπραγμάτευτη.

Συνολικά, η σύγκριση αυτή οδηγεί στο συμπέρασμα ότι η πλήρης αξιοποίηση των Generative AI μοντέλων προϋποθέτει συνδυασμό τεχνολογικής υπεροχής και ακαδημαϊκής πειθαρχίας, ενώ η μελλοντική τους χρήση στην υποστήριξη κρίσιμων τομέων όπως η κυβερνοασφάλεια προδιαγράφεται πολλά υποσχόμενο, εφόσον αναπτυχθούν περαιτέρω επεξηγηματικοί και αξιόπιστοι μηχανισμοί.

Παράρτημα Α: Prompts που χρησιμοποιήθηκαν

Α.1 Prompts προς ChatGPT (OpenAI)

- **Περιγραφή**: Το εργαλείο ChatGPT χρησιμοποιήθηκε για την παραγωγή του κειμένου του Μέρους Α της εργασίας ("Θεωρητική Ανάλυση και Τρέχουσες Εφαρμογές").
- **Prompt που δόθηκε**:

«Σύνταξε μια αναλυτική εργασία για το θέμα: Generative AI για Ανίχνευση Επιθέσεων Zero-Day.

Να περιλαμβάνει:

→Ορισμό και χαρακτηριστικά επιθέσεων zero-day.
→Εξήγηση βασικών αρχών λειτουργίας Generative AI**.**
→Πώς τα Generative AI μοντέλα μπορούν να ανιχνεύσουν επιθέσεις τύπου zero-day.
→Παραδείγματα εφαρμογών (GANs, VAEs, LLMs, XDR, Explainable AI).
→Ανάλυση πλεονεκτημάτων και περιορισμών αυτής της προσέγγισης.»

Α.2 Prompts προς Claude 3 (Anthropic)

- **Περιγραφή:** Το εργαλείο Claude 3 χρησιμοποιήθηκε για τη σύνθεση νέου κειμένου στο πλαίσιο του Μέρους Β της εργασίας ("Διαφορική Αξιολόγηση του AI") και για τη διασταύρωση των πληροφοριών.
- **Prompt που δόθηκε:**

«Γράψε μια ακαδημαϊκή ανάλυση για το θέμα: *Generative AI για Ανίχνευση Επιθέσεων ZeroDay*.

Να αναπτύξεις:

→Ορισμό και επικινδυνότητα των zero-day επιθέσεων.
→Θεμελιώδεις αρχές και αρχιτεκτονικές Generative AI (GANs, VAEs, Transformers).
→Πρακτικές εφαρμογές στον τομέα της κυβερνοασφάλειας.
→Μελέτες περίπτωσης πραγματικών εφαρμογών.
→Πλεονεκτήματα, περιορισμούς και μελλοντικές κατευθύνσεις της χρήσης Generative AI στην ανίχνευση zero-day επιθέσεων.»

Βιβλιογραφία

- An, J. and Cho, S. (2015) 'Variational Autoencoder based Anomaly Detection using Reconstruction Probability', Special Lecture on IE, 2(1), pp. 1–18.
- Baltrusaitis, T., Ahuja, C. and Morency, L.P. (2019) 'Multimodal Machine Learning: A Survey and Taxonomy', IEEE Transactions on Pattern Analysis and Machine Intelligence, 41(2), pp. 423–443.
- Biggio, B. and Roli, F. (2018) 'Wild Patterns: Ten Years After the Rise of Adversarial Machine Learning', Pattern Recognition, 84, pp. 317–331.
- Brundage, M. et al. (2018) 'The Malicious Use of Artificial Intelligence: Forecasting, Prevention, and Mitigation', arXiv preprint arXiv:1802.07228.
- Buczak, A.L. and Guven, E. (2016) 'A Survey of Data Mining and Machine Learning Methods for Cyber Security Intrusion Detection', IEEE Communications Surveys & Tutorials, 18(2), pp. 1153–1176.
- Carlini, N. et al. (2021) 'Extracting Training Data from Large Language Models', Proceedings of the 30th USENIX Security Symposium.
- Chandola, V., Banerjee, A. and Kumar, V. (2009) 'Anomaly detection: A survey', ACM Computing Surveys, 41(3), pp. 1–58.
- Devlin, J., Chang, M.W., Lee, K. and Toutanova, K. (2019) 'BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding', Proceedings of NAACL-HLT, pp. 4171–4186.
- Doshi-Velez, F. and Kim, B. (2017) 'Towards A Rigorous Science of Interpretable Machine Learning', arXiv preprint arXiv:1702.08608.
- Goodfellow, I., Bengio, Y. and Courville, A. (2016) Deep Learning. MIT Press.
- Google DeepMind (2024) Introducing Gemini 1.5. Available at: https://deepmind.google
- Kim, G., Lee, S. and Kim, S. (2014) 'A novel hybrid intrusion detection method integrating anomaly detection with misuse detection', Expert Systems with Applications, 41(4), pp. 1690–1700.
- Lemos, R. (2023) 'Large Language Models for Cybersecurity: Opportunities and Challenges', Dark Reading.
- Lin, Z., Shi, R., Xue, M. and Xu, W. (2020) 'IDSGAN: Generative Adversarial Networks for Attack Generation against Intrusion Detection', arXiv preprint arXiv:2003.09135.
- Moustafa, N. et al. (2023) 'Harnessing AI for Zero-Day Attack Detection in Cybersecurity', IEEE Access, 11, pp. 43255–43270.
- Patcha, A. and Park, J.M. (2007) 'An overview of anomaly detection techniques: Existing solutions and latest technological trends', Computer Networks, 51(12), pp. 3448–3470.

- Raffel, C. et al. (2020) 'Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer', Journal of Machine Learning Research, 21(140), pp. 1–67.
- Russell, S. and Norvig, P. (2020) Artificial Intelligence: A Modern Approach, 4th ed. Pearson.
- Samek, W., Wiegand, T. and Müller, K.R. (2017) 'Explainable Artificial Intelligence: Understanding, Visualizing and Interpreting Deep Learning Models', arXiv preprint arXiv:1708.08296.
- Shone, N., Ngoc, T.N., Phai, V.D. and Shi, Q. (2018) 'A Deep Learning Approach to Network Intrusion Detection', IEEE Transactions on Emerging Topics in Computational Intelligence, 2(1), pp. 41–50.
- Sommer, R. and Paxson, V. (2010) 'Outside the Closed World: On Using Machine Learning for Network Intrusion Detection', IEEE Symposium on Security and Privacy, pp. 305–316.
- Strohmeier, M. et al. (2018) 'The Threat of AI-Generated Cyberattacks', IEEE Security & Privacy, 16(5), pp. 61–65.
- Yu, S., Liu, X. and Song, H. (2019) 'Reinforcement learning in cybersecurity: State-of-the-art and future directions', Computers & Security, 87, 101568.